ClinDistill

Literature Review & Reading Guide

Privileged Clinical-Context-Guided Multi-Image Learning for Visual-Only Oro-Dental Diagnosis

Phạm vi khởi đầu: CODe + MeMoSA

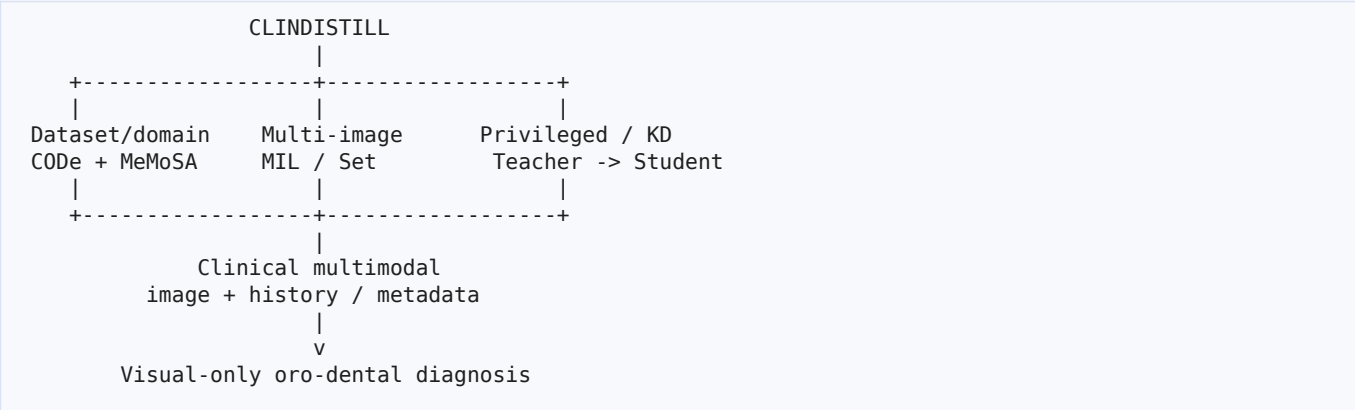
Tài liệu tham khảo trước khi thiết kế và triển khai khóa luận

Cập nhật: 11/09/2026

Mục tiêu: Tài liệu này không chỉ liệt kê paper. Mỗi paper được tóm theo: bài toán, lý thuyết, cấu trúc, cách train, kết quả chính, và phần nào có thể dùng để xây ClinDistill. Tất cả link paper chính được gắn trực tiếp và có thể bấm trong PDF.

1. Bản đồ literature cho ClinDistill

Ý tưởng khóa luận hiện tại nằm ở giao của bốn nhánh nghiên cứu. Không nên đọc paper theo một danh sách phẳng; nên đọc theo bốn khối dưới đây rồi ghép lại thành kiến trúc.



Bốn nhánh literature cần ghép lại để hình thành ClinDistill.

Nhánh	Vai trò trong ClinDistill
Khối A - Dataset	CODe và MeMoSA: hiểu unit dữ liệu, label, clinical fields, multi-image grouping và nguy cơ leakage.
Khối B - Multi-image	Attention MIL, Set Transformer, patient-level MIL: nhiều ảnh của cùng một case -> một representation cấp bệnh nhân/checkup.
Khối C - Clinical multimodal	Dental report + X-ray, oral image + metadata, DentVLM: cách visual và clinical information bổ sung cho nhau.
Khối D - Privileged KD	LUPI, generalized distillation, MMPKD, CPKD, TriDeNT: dùng thông tin mạnh hơn khi train nhưng bỏ ở inference.

Kết luận nhanh từ literature: Novelty không nên chỉ là "dùng clinical text làm Teacher rồi KD sang image Student", vì privileged/multimodal KD đã có. Khoảng trống đáng nhắm là: multi-image cấp case + clinical-field-aware/selective transfer + phân biệt knowledge nhìn thấy được từ ảnh và knowledge chỉ có trong tiền sử/risk factors + kiểm chứng trên hai oral/dental domain khác nhau.

1.1 Kiến trúc khởi đầu được suy ra từ literature

```
CODe:   Photos + X-rays -----> Visual encoder(s) ----+
                                                     |
MeMoSA: Multiple photos -----> Visual encoder ------+--> Multi-image aggregator --> z_visual -->
Student head
                                                                                        ^
Clinical fields --> field grouping --> Text/clinical encoder --> Multimodal Teacher ----| KD

TRAIN:  images + privileged clinical context
TEST:   images only
```

- CODe và MeMoSA nên train/evaluate độc lập trước; cùng framework nhưng label head và preprocessing theo từng dataset.
- Sau khi hai pipeline riêng ổn mới thử shared backbone / shared weights giữa hai dataset.
- Diagnosis, biopsy result, treatment/referral fields cần được audit và mask/loại khỏi Teacher nếu chúng chứa trực tiếp target.
- Multi-image unit phải theo patient/checkup/encounter, không split theo từng ảnh để tránh leakage giữa train và test.

2. Paper review chi tiết

Mỗi paper dưới đây được đọc theo cùng một khung: lý thuyết -> cấu trúc -> cách train -> kết quả cần nhớ -> phần có thể kế thừa cho ClinDistill.

Peer-reviewed

A benchmark multimodal oro-dental dataset for large vision-language models (CODe)

Lv et al. | Scientific Data | 2026 | Data Descriptor

Paper: https://doi.org/10.1038/s41597-026-07342-9

Vì sao cần đọc: Đây là paper dataset chính của nhánh CODe. Cần đọc trước khi code vì nó quyết định unit học, cách group nhiều ảnh, text fields, benchmark gốc và những phần bạn không nên lặp lại như contribution.

1. Lý thuyết / ý tưởng chính

- CODe tổ chức dữ liệu theo dental check-up: mỗi check-up có nhiều intraoral photographs, radiographs và một detailed clinical record.
- Dataset gồm 8,775 checkups của 4,800 patients, khoảng 50,000 intraoral photos và 8,056 radiographs.
- Clinical record có Chief Complaint, Present Illness, Past Medical Record, Examination, Radiographic Examination, Diagnosis, Treatment Plan, Management, Medical Instructions và Remarks.
- Benchmark gốc đã làm 6-class anomaly classification và diagnostic report generation; vì vậy lặp lại Qwen-VL fine-tuning thuần túy không tạo novelty mạnh.

2. Cấu trúc / pipeline

```
Checkup
  |-- Photo_1, Photo_2, ...
  |-- Radiograph_1, Radiograph_2, ...
  `-- Clinical record
          |
          +--> Qwen-VL benchmark
                 |-- 6-class anomaly classification
                 `-- diagnostic report generation
```

3. Cách train / cơ chế học

- Paper gốc fine-tune Qwen-VL-3B và Qwen-VL-7B bằng LoRA trong 3 epochs; benchmark classification dùng Age, Gender, Chief Complaint, Radiographs và Photographs.
- Generation benchmark còn dùng Past Medical History và yêu cầu sinh một full dental report.
- Với ClinDistill, nên dùng patient/checkup-disjoint split và biến “one checkup = one bag of images” cho multi-image learning.

4. Kết quả / kết luận cần nhớ

- Fine-tuned Qwen-VL-7B đạt khoảng 78.92% accuracy và 79.39% F1 trên benchmark 6 anomaly của paper.
- Paper chứng minh CODe hữu ích cho multimodal dental AI, nhưng chưa giải quyết bài toán privileged clinical context -> visual-only Student theo hướng ClinDistill.

5. Liên hệ trực tiếp với ClinDistill

- CODe là dataset phù hợp nhất để kiểm tra: multi-image + multiple visual modalities (photo/X-ray) + rich clinical record.
- Các field Examination và Radiographic Examination có visual grounding cao; Diagnosis lại có nguy cơ target leakage nếu dùng làm input Teacher.
- CODe nên là dataset phát triển method đầu tiên vì grouping theo checkup rõ ràng.

6. Nên học gì từ paper này

- Học cách tổ chức data theo checkup và xây patient-disjoint split.
- Dùng benchmark gốc như baseline tham khảo, không coi đó là contribution mới.

- Tạo ablation Photo-only, X-ray-only, Photo+X-ray, rồi mới thêm Clinical Teacher/KD.

Peer-reviewed

MeMoSA dataset: A multi-country collection of over 30,000 oral mucosa images with clinically labelled lesions

Chew et al. | Scientific Data | 2026 | Data Descriptor

Paper: https://doi.org/10.1038/s41597-026-06998-7

Vì sao cần đọc: MeMoSA là dataset quan trọng nhất để kiểm tra clinical dependency: ảnh lesion đi kèm history, symptoms và behavioural risk factors mà visual Student không thể trực tiếp nhìn thấy.

1. Lý thuyết / ý tưởng chính

- Dataset gồm 30,039 oral mucosa images từ cohorts ở 5 quốc gia; ảnh được chụp bằng mobile devices và đi kèm patient/lesion metadata.
- Metadata có age, gender, ethnicity, smoking, betel quid, alcohol, duration của các habits, clinical presentation, chief complaint, history of presenting complaint, medication history, medical history, biopsy/investigations, diagnosis, referral và image quality.
- Six lesion-type classes gồm oral cancer, OPMD, benign lesions, developmental anomalies, normal anatomical variants và no lesion.
- Một phần lớn dữ liệu teleconsultation được chẩn đoán từ nhiều ảnh chụp trong cùng clinical encounter; đây là cơ sở để xây multi-image case-level model.

2. Cấu trúc / pipeline

```
Encounter / patient
  |-- Oral photo_1
  |-- Oral photo_2
  |-- Oral photo_3 ...
  `-- Clinical context
        |-- symptoms / complaint
        |-- medical history
        `-- smoking / alcohol / betel / duration
                    |
                    v
              lesion diagnosis
```

3. Cách train / cơ chế học

- Paper là data descriptor, không đưa một ClinDistill-style Teacher-Student architecture; nhiệm vụ của bạn là thiết kế model từ metadata đã được chuẩn hóa.
- Khi lấy dữ liệu thật cần audit chính xác encounter/follow-up identifiers trước khi group ảnh thành bag.
- Nên tách clinical fields thành nhóm visual-grounded, partially visual và clinical-only để phục vụ selective KD.

4. Kết quả / kết luận cần nhớ

- Ground truth được xác minh bằng biopsy khi có; các case còn lại dùng expert review/consensus theo protocol mô tả trong paper.
- Paper chủ động giữ cả ảnh chất lượng kém để phản ánh real-world mobile acquisition, tạo domain shift mạnh hơn CODe.

5. Liên hệ trực tiếp với ClinDistill

- MeMoSA là nơi ClinDistill có thể chứng minh rằng Teacher tận dụng risk factors/history nhưng Student không nên bị ép “đoán” các thông tin không nhìn thấy từ ảnh.
- Đây là dataset phù hợp để phát triển Clinical Dependency / Visual Sufficiency score hoặc field-aware distillation.
- Có thể dùng MeMoSA như independent validation của method sau khi pipeline CODe ổn.

6. Nên học gì từ paper này

- Audit encounter grouping và patient-disjoint split.
- Mask Clinical diagnosis, biopsy result và referral nếu chúng trực tiếp hoặc gần trực tiếp tiết lộ target.
- Dùng image quality metadata cho robustness/ablation, nhưng không để nó vô tình trở thành shortcut cho label.

Peer-reviewed

Clinical priors-inspired privileged knowledge distillation for reliable pancreatic lesion classification (CPKD)

Han et al. | Medical Image Analysis 111:104041 | 2026

Paper: https://doi.org/10.1016/j.media.2026.104041

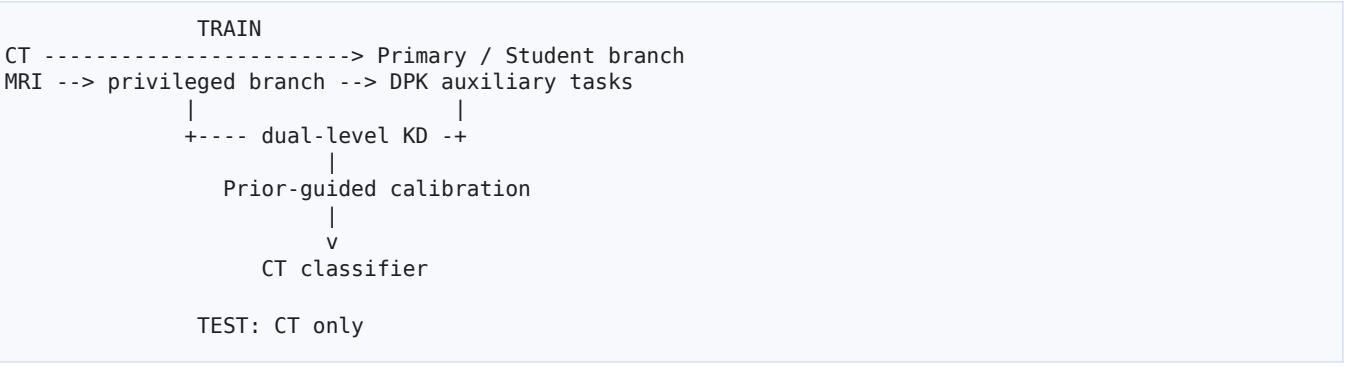
Code: https://github.com/Hanqiaoyu/CPKD

Vì sao cần đọc: Đây là prior art gần nhất về "privileged information chỉ có lúc train nhưng inference chỉ dùng primary modality". Nó cho thấy novelty của ClinDistill phải vượt quá vanilla privileged KD.

1. Lý thuyết / ý tưởng chính

- CPKD dùng CT làm primary modality và MRI làm privileged modality; mục tiêu cuối là CT-only inference.
- Paper đưa clinical priors trực tiếp vào cơ chế distillation thay vì chỉ KL logits đơn giản.
- Hai ý chính: Diagnosis-related Privileged Knowledge (DPK) dùng auxiliary tasks để lấy knowledge chẩn đoán từ privileged modality; Prior-guided Dual Calibration (PDC) dùng biological prediction calibration và personalized distillation calibration.
- Dual-level distillation cho thấy knowledge có thể truyền ở nhiều cấp, không nhất thiết chỉ ở output logits.

2. Cấu trúc / pipeline



3. Cách train / cơ chế học

- Privileged branch khai thác MRI để tạo diagnosis-related knowledge.
- Knowledge được distill sang CT branch ở hai mức; PDC tăng guidance cho các challenging samples và hiệu chỉnh prediction theo clinical/biological priors.
- Code được authors công bố tại GitHub; nên đọc code sau khi hiểu paper để xem exact loss và training schedule.

4. Kết quả / kết luận cần nhớ

- Paper báo cáo CPKD vượt các competing methods trên multi-center dataset; đặc biệt cải thiện mạnh ở subgroup small/isoattenuating lesions.
- Bài học quan trọng không phải con số cụ thể mà là: "privileged modality" cần được lọc/định hướng bằng prior, nếu không mọi thông tin phụ đều không có giá trị như nhau.

5. Liên hệ trực tiếp với ClinDistill

- ClinDistill có thể chuyển logic "clinical-prior-guided transfer" sang "field-aware / visualizability-aware clinical text transfer".
- Thay MRI privileged modality bằng clinical context; thay CT primary modality bằng multi-image visual representation.
- CPKD là paper reviewer rất dễ dùng để hỏi: "phương pháp của bạn khác gì?"

6. Nên học gì từ paper này

- Không dừng ở vanilla logits KD nếu muốn paper mạnh.
- Thiết kế gating/weighting theo clinical field hoặc theo sample difficulty.
- Đưa ablation: vanilla KD vs selective/field-aware KD.

Preprint (chưa peer-reviewed)

On the effectiveness of multimodal privileged knowledge distillation in two vision transformer based diagnostic applications (MMPKD)

Baur et al. | arXiv:2508.06558 | 2025

Paper: https://arxiv.org/abs/2508.06558

Vì sao cần đọc: Paper này gần ClinDistill ở chỗ Teacher có text/metadata còn Student là ViT image-only. Nó cũng cảnh báo rằng privileged KD không phải lúc nào cũng giúp ở mọi domain.

1. Lý thuyết / ý tưởng chính

- MMPKD formalize x = image, x* = privileged text/tabular information, y = diagnosis.
- Teacher được train chỉ trên privileged modality; sau đó đóng băng Teacher và lấy soft labels để hướng dẫn Student vision model.
- Inference chỉ cần image x, vì x* chỉ tồn tại ở training.
- Paper test hai setting: MIMIC-CXR với text report Teacher và CBIS-DDSM với tabular metadata Teacher.

2. Cấu trúc / pipeline

```
Step 1: x* (text/metadata) --> Teacher --> soft labels s
                                    | freeze
Step 2: image x --> ViT Student ----+--> CE(y) + distillation(s)

Inference: image x --> Student only
```

3. Cách train / cơ chế học

- Student objective kết hợp ground-truth loss và soft-label distillation loss với trọng số lambda; temperature T làm mềm teacher prediction.
- MIMIC-CXR Teacher dùng PubMedBERT (loại label names khỏi reports); CBIS-DDSM Teacher dùng Random Forest trên metadata.
- Student dùng ViT-Tiny pretrained ImageNet và authors grid-search lambda/T.

4. Kết quả / kết luận cần nhớ

- MMPKD cải thiện zero-shot ROI localization qua attention maps ở MIMIC-CXR nhưng không lặp lại benefit tương tự trên CBIS-DDSM.
- Predictive AUROC gần như ổn định ở một số setting; kết quả nhấn mạnh tính dataset-dependent của privileged distillation.

5. Liên hệ trực tiếp với ClinDistill

- Đây là baseline lý tưởng cho ClinDistill: field-agnostic soft-label KD.
- ClinDistill cần chứng minh selective/field-aware transfer tốt hơn hoặc đáng tin hơn vanilla MMPKD trên CODe/MeMoSA.
- Kết quả không đồng nhất giữa datasets ủng hộ việc bạn đánh giá method độc lập trên cả CODe và MeMoSA.

6. Nên học gì từ paper này

- Dùng loss MMPKD làm baseline tối thiểu.
- Tách evaluation prediction và explanation/attention; không coi attention map là giải thích đáng tin tuyệt đối.
- Báo cáo mean/std nhiều seeds vì effect có thể biến thiên mạnh.

Peer-reviewed

TriDeNT: Triple deep network training for privileged knowledge distillation in histopathology

Farndale, Insall & Yuan | Medical Image Analysis 102:103479 | 2025

Paper: https://doi.org/10.1016/j.media.2025.103479

Vì sao cần đọc: TriDeNT quan trọng vì nó cho một cách khác với supervised Teacher-soft-label KD: dùng privileged data để cải thiện representation learning của primary input, rồi deployment chỉ dùng primary encoder.

1. Lý thuyết / ý tưởng chính

- TriDeNT là self-supervised privileged representation learning cho pathology.
- Primary data là routine H&E; privileged data có thể là IHC, spatial transcriptomics hoặc expert nuclei annotations - những thứ đắt/không có khi inference.
- Ý tưởng ba nhánh: hai augmented views của primary input đi qua shared primary encoder; nhánh thứ ba xử lý privileged input bằng encoder riêng.
- Self-supervised objective buộc representations liên quan giữa các views/modalities, nhưng vẫn giữ khả năng học feature chỉ có ở primary input tốt hơn so với naive Siamese cross-modal matching.

2. Cấu trúc / pipeline

```
Primary x --aug1--> Primary encoder --+
Primary x --aug2--> Primary encoder --+--> SSL objective / joint representation
Privileged x* -----> Privileged enc ---+
                                       |
                           pretrain primary encoder
                                       |
                          small labelled dataset
                                       v
                              downstream classifier
                                       |
                              inference on primary x
```

3. Cách train / cơ chế học

- Giai đoạn 1: self-supervised pretraining với primary + privileged paired data.
- Giai đoạn 2: bỏ privileged encoder, gắn classifier head lên primary encoder và fine-tune/linear probe với labelled data.
- TriDeNT phù hợp khi bạn muốn privileged context tác động vào feature space chứ không chỉ output probability.

4. Kết quả / kết luận cần nhớ

- Authors báo cáo improvement mạnh trên nhiều privileged pathology settings và few-shot downstream tasks.
- Bài học lớn: privileged information có thể dùng để shape representation trước khi classifier được huấn luyện.

5. Liên hệ trực tiếp với ClinDistill

- Có thể truyền cảm hứng cho “feature KD” giữa multimodal Teacher representation và visual Student representation.
- ClinDistill không cần sao chép ba nhánh TriDeNT, nhưng nên có baseline/ablation logit KD vs feature KD.
- Nếu sau này làm pretraining chung CODe+MeMoSA, self-supervised privileged representation learning là extension đáng cân nhắc.

6. Nên học gì từ paper này

- Đọc để hiểu vì sao representation-level transfer khác logit-level transfer.
- Không cần triển khai TriDeNT ngay ở bản khóa luận đầu; ưu tiên supervised baseline trước.
- Giữ ý tưởng privileged data chỉ là “teacher signal”, không phải input bắt buộc lúc test.

Peer-reviewed

A holistic approach for classifying dental conditions from textual reports and panoramic radiographs

Silva et al. | Medical Image Analysis 105:103709 | 2025

Paper: https://doi.org/10.1016/j.media.2025.103709

Vì sao cần đọc: Paper rất sát domain nha khoa: text report + dental radiograph. Nó không dùng KD như ClinDistill, nhưng cho biết text lâm sàng có thể được khai thác để tạo supervision cho image model.

1. Lý thuyết / ý tưởng chính

- Bài toán: thiếu tooth-level labels cho panoramic radiographs.
- Authors dùng LLM để extract dental conditions từ textual reports như một auto-labeling step.
- Instance segmentation network tách từng tooth; sau đó linkage procedure ghép condition trong report với tooth tương ứng.
- Image classifier được huấn luyện từ labels sinh/ghép từ report, tức text đóng vai trò supervision source thay vì inference modality.

2. Cấu trúc / pipeline

```
Textual report --> LLM --> condition mentions ----+
                                                  | linkage --> tooth-condition labels
Panoramic X-ray --> tooth instance segmentation -+
                                                  |
                                                  v
                                      dental condition classifier
```

3. Cách train / cơ chế học

- Pipeline trước hết xử lý text để rút condition labels, rồi xử lý radiograph để segment teeth, sau đó liên kết hai phía.
- Approach mang tính semi-supervised / weakly supervised vì không cần một bộ tooth-level annotation trực tiếp đầy đủ.
- Hai datasets của study có 8,795 panoramic radiographs và 8,029 paired reports/images.

4. Kết quả / kết luận cần nhớ

- Paper báo cáo vượt baseline theo Matthews correlation coefficient và so sánh với dental professionals.
- Điểm cần nhớ: report text có thể biến thành supervision rất hữu ích, nhưng đây không phải Teacher-Student privileged distillation.

5. Liên hệ trực tiếp với ClinDistill

- Cho ClinDistill một related-work dental trực tiếp về image-text relationship.
- Có thể dùng tư duy “clinical text không chỉ là raw sentence; phải map/structure thông tin trước khi dùng”.
- Đây là lý do field grouping / sentence weighting trong ClinDistill hợp lý hơn concat toàn bộ report.

6. Nên học gì từ paper này

- Học cách audit report-derived label leakage.
- Tách tooth/region-level supervision nếu sau này thêm Tooth/Region heads.
- Không claim novelty chung chung là “dùng report text để cải thiện dental image model”.

Peer-reviewed

Multimodal oral cancer detection with embedding-level oversampling of fused image and clinical data

Ormeño-Arriagada et al. | Scientific Reports | 2026

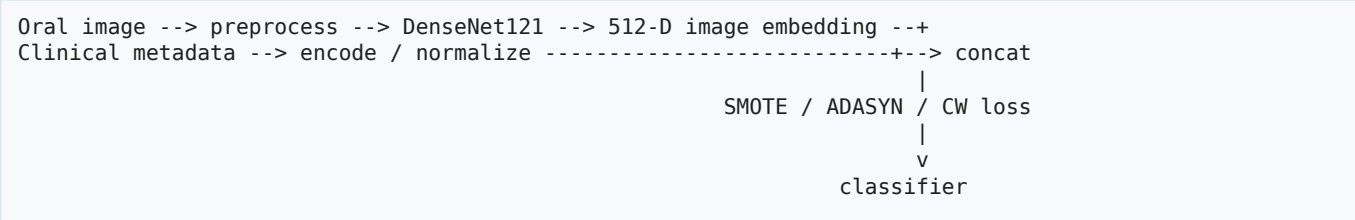
Paper: https://doi.org/10.1038/s41598-026-52410-0

Vì sao cần đọc: Paper này là bằng chứng trực tiếp trong oral lesion domain rằng image + clinical metadata/risk factors có thể tốt hơn image-only dưới protocol được đánh giá. Nó rất gần vai trò Teacher của MeMoSA.

1. Lý thuyết / ý tưởng chính

- Visual branch dùng pretrained CNN để tạo image embedding; public accepted manuscript mô tả DenseNet121 và embedding 512-D.
- Clinical metadata gồm age, sex và behavioural risk factors như smoking, alcohol, betel-quid chewing.
- Late fusion bằng concatenation image embedding + metadata vector.
- Đóng góp chính là oversampling ở fused embedding space bằng SMOTE/ADASYN để xử lý class imbalance.

2. Cấu trúc / pipeline



3. Cách train / cơ chế học

- Authors so sánh image-only, multimodal fusion không oversampling, và multimodal fusion + embedding-level oversampling.
- Oversampling chỉ áp dụng trên training partition; metadata categorical one-hot, continuous variables z-score normalization.
- Paper dùng một controlled single-center experimental setup nên external generalization còn hạn chế.

4. Kết quả / kết luận cần nhớ

- Best multimodal configurations cải thiện class-balanced metrics so với image-only baselines trong protocol của study.
- Authors nhấn mạnh result nên hiểu trong phạm vi controlled setup, không phải bằng chứng clinical generalization rộng.

5. Liên hệ trực tiếp với ClinDistill

- Trực tiếp ủng hộ MeMoSA Teacher dùng risk factors + image.
- ClinDistill khác ở chỗ clinical metadata không cần ở inference: multimodal Teacher -> visual Student.
- Bạn có thể dùng simple late-fusion Teacher như baseline trước khi xây cross-attention Teacher phức tạp.

6. Nên học gì từ paper này

- Bắt đầu Teacher đơn giản: concat z_visual + z_clinical -> MLP classifier.
- Trước khi nghĩ transformer fusion, phải chứng minh clinical context thực sự thêm signal.
- Báo cáo class imbalance metrics như macro-F1/AUROC và per-class recall, không chỉ accuracy.

Peer-reviewed

A multimodal vision-language model for comprehensive dental diagnosis and enhanced clinical practice (DentVLM)

Meng et al. | Nature Communications | 2026

Paper: https://doi.org/10.1038/s41467-026-75718-x

Vì sao cần đọc: DentVLM cho bức tranh state-of-the-art dental multimodal 2026: nhiều visual modalities, 36 tasks, VQA, reasoning. Nó giúp bạn đặt ClinDistill đúng vị trí: nhẹ hơn, deploy image-only và nghiên cứu knowledge transfer thay vì xây một VLM khổng lồ.

1. Lý thuyết / ý tưởng chính

- DentVLM dựa trên Qwen2-VL-7B và xử lý 7 loại 2D oral imaging: PAN, LAT và 5 intraoral views.
- Dataset huấn luyện có 110,447 images và khoảng 2.46M bilingual VQA pairs, bao phủ 36 tasks.
- Output có diagnosis, rationale và optional localization.
- Training hai stage: Vision-Language Alignment trên số lượng lớn simple VQA; sau đó Diagnosis Instruction Tuning trên subset chất lượng cao có rationale/localization.

2. Cấu trúc / pipeline

```
7 dental image modalities --> Qwen2-VL vision encoder --> vision tokens
Question ------------------------------------------------> LLM decoder
                                                           |
             Stage 1: vision-language alignment            |
             Stage 2: diagnosis instruction tuning         |
                                                           v
                                          diagnosis + rationale + location
```

3. Cách train / cơ chế học

- Stage 1 dùng khoảng 2.37M simple VQA pairs; cả vision encoder và LLM decoder được train.
- Stage 2 dùng khoảng 88.6K high-quality high-resolution VQA pairs; public description cho biết vision encoder được freeze và LLM decoder được fine-tune.
- Đây là full multimodal/VLM inference, không phải privileged clinical context only-at-training.

4. Kết quả / kết luận cần nhớ

- Paper báo cáo strong internal/external results và reader study; Nature Communications version dùng 32 participants trong clinical evaluation.
- Quan trọng nhất với khóa luận: multi-view/multi-task dental VLM đã tồn tại, nên novelty ClinDistill phải nằm ở efficient visual-only deployment + selective knowledge transfer.

5. Liên hệ trực tiếp với ClinDistill

- Dùng DentVLM làm “state-of-the-art dental multimodal” trong Related Work.
- Không cần cạnh tranh scale trực tiếp với VLM 7B; thesis của bạn có research question khác.
- Có thể mượn tư duy modality/view-aware preprocessing và external evaluation.

6. Nên học gì từ paper này

- Giữ scope gọn: 2D encoders + MIL + Teacher-Student trước.
- Đừng biến khóa luận thành VQA/generative diagnosis trừ khi core ClinDistill đã hoàn tất.
- Nhấn mạnh deployment advantage: Student không cần clinical text/VLM lớn lúc inference.

Peer-reviewed

Knowledge distillation and teacher-student learning in medical imaging: Comprehensive overview, pivotal role, and future directions

Li et al. | Medical Image Analysis 107:103819 | 2026 | Survey

Paper: https://doi.org/10.1016/j.media.2025.103819

Vì sao cần đọc: Đây là survey nên đọc trước khi chốt loss. Nó giúp bạn không "phát minh lại" các dạng KD đã có và xây taxonomy baseline hợp lý.

1. Lý thuyết / ý tưởng chính

- Knowledge Distillation truyền knowledge từ teacher sang student; trong medical imaging KD không chỉ dùng để model compression mà còn cho missing modalities, domain adaptation, semi-supervision và nhiều vai trò khác.
- Three families cần phân biệt khi code: response/logit-based KD, feature-based KD và relation/structure-based KD.
- Cross-modal/privileged KD là trường hợp Teacher và Student nhìn các nguồn dữ liệu khác nhau hoặc Teacher có modality nhiều hơn.

2. Cấu trúc / pipeline

```
Teacher output ---------> logit / response KD ----+
Teacher features -------> feature KD -------------+--> Student
Teacher relations ------> relation KD ------------+
Ground truth -----------------------------------> supervised loss
```

3. Cách train / cơ chế học

- Với ClinDistill nên bắt đầu từ supervised CE/BCE + vanilla logit KD.
- Sau đó thêm feature alignment hoặc relation KD thành controlled ablation, không thêm đồng thời mọi loss ngay từ đầu.
- Chỉ giữ loss phức tạp nếu nó tạo improvement ổn định trên validation và nhiều seeds.

4. Kết quả / kết luận cần nhớ

- Survey định nghĩa nhiều vai trò của KD trong medical imaging và tổng hợp working principles/limitations.
- Giá trị của paper là taxonomy và bibliography, không phải một architecture duy nhất.

5. Liên hệ trực tiếp với ClinDistill

- Dùng survey để chọn baseline KD và thuật ngữ chính xác trong thesis.
- Giúp viết Related Work: model compression vs cross-modal knowledge transfer vs missing-modality learning.
- Có thể dùng bảng taxonomy của survey làm checklist khi thiết kế ablation.

6. Nên học gì từ paper này

- Đọc phần cross-modal/multimodal KD trước.
- Chốt một loss tối giản trước khi thêm selective weighting.
- Không dùng quá nhiều KD loss khiến khó biết contribution nào thực sự hiệu quả.

Peer-reviewed

Attention-based Deep Multiple Instance Learning

Ilse, Tomczak & Welling | ICML / PMLR 80 | 2018

Paper: https://proceedings.mlr.press/v80/ilse18a.html

Vì sao cần đọc: Đây là baseline multi-image phù hợp nhất để bắt đầu: nhiều ảnh cùng một case tạo thành một bag và chỉ cần label cấp bag/checkup/patient.

1. Lý thuyết / ý tưởng chính

- Multiple Instance Learning (MIL): một bag chứa nhiều instances nhưng label chỉ có ở cấp bag.
- Paper đề xuất attention-based permutation-invariant aggregation, cho model tự học ảnh/instance nào quan trọng hơn cho bag label.
- Attention weights cung cấp một mức interpretability ở instance level, dù không nên xem là causal explanation.

2. Cấu trúc / pipeline

```
Image_1 --> encoder --> h1 --a1--+
Image_2 --> encoder --> h2 --a2--+--> weighted sum z_bag --> classifier
Image_3 --> encoder --> h3 --a3--+
...
where sum(a_i)=1
```

3. Cách train / cơ chế học

- Mỗi ảnh dùng cùng encoder weights; không phải N ảnh = N models.
- Attention network sinh a_i từ h_i; bag representation z là weighted sum các h_i.
- Loss tính ở bag-level prediction so với patient/checkup label.

4. Kết quả / kết luận cần nhớ

- Paper đạt competitive/strong performance trên benchmark MIL và histopathology datasets.
- Quan trọng với ClinDistill: architecture xử lý variable number of images tự nhiên và giữ permutation invariance.

5. Liên hệ trực tiếp với ClinDistill

- CODe: one checkup = one bag; MeMoSA: one validated encounter/patient grouping = one bag sau audit.
- Dùng Attention MIL làm baseline mạnh trước Set Transformer.
- Có thể distill Teacher bag representation sang Student bag representation.

6. Nên học gì từ paper này

- Baseline sequence: mean pooling -> max pooling -> Attention MIL.
- Log attention weights để xem model tập trung ảnh nào, nhưng không dùng chúng như bằng chứng giải thích tuyệt đối.
- Hỗ trợ variable-N images bằng padding mask hoặc list/bag sampling.

Peer-reviewed

Set Transformer: A Framework for Attention-based Permutation-Invariant Neural Networks

Lee et al. | ICML / PMLR 97 | 2019

Paper: https://proceedings.mlr.press/v97/lee19d.html

Vì sao cần đọc: Set Transformer là lựa chọn nâng cao khi bạn muốn các ảnh trong một case tương tác với nhau, thay vì chỉ tính attention weight độc lập rồi pooling.

1. Lý thuyết / ý tưởng chính

- Input là một set nên thứ tự phần tử không nên làm thay đổi output.
- Self-attention cho phép model học interaction giữa các instances: ví dụ ảnh toàn cảnh có thể bổ sung ảnh close-up.
- Induced Set Attention Blocks giảm complexity so với self-attention đầy đủ khi số instances lớn.

2. Cấu trúc / pipeline

```
{h1, h2, ..., hN}
        |
 Set Attention Blocks
        |  (instance-instance interaction)
        v
 Pooling by Multihead Attention
        |
        v
   set representation --> classifier
```

3. Cách train / cơ chế học

- Train end-to-end từ bag label.
- Có thể dùng mask cho số ảnh khác nhau giữa các case.
- Với CODe, có thể thêm modality/type embedding (photo vs X-ray) trước set attention; đây là extension của bạn chứ không phải nội dung gốc paper.

4. Kết quả / kết luận cần nhớ

- Paper chứng minh framework phù hợp nhiều set-structured tasks và permutation-invariant learning.
- Không có dental/clinical context; relevance nằm ở aggregator architecture.

5. Liên hệ trực tiếp với ClinDistill

- So sánh Attention MIL vs Set Transformer là một ablation multi-image tốt.
- Chỉ dùng Set Transformer sau khi simple MIL baseline ổn để tránh debug quá nhiều thành phần cùng lúc.
- Có thể thử cross-image interaction khi CODe có nhiều views/modalities.

6. Nên học gì từ paper này

- Giữ embedding dimension nhỏ ở prototype để giảm VRAM.
- Dùng padding mask cẩn thận để padded images không nhận attention.
- Không coi Set Transformer là novelty chính nếu chỉ áp dụng nguyên bản.

Peer-reviewed

Patient-level thyroid cancer classification using attention multiple instance learning on fused multi-scale ultrasound image features

Zhuang et al. | AMIA Annual Symposium Proceedings 2023 (published 2024)

Paper: https://pmc.ncbi.nlm.nih.gov/articles/PMC10785838/

Vì sao cần đọc: Đây là ví dụ medical thực tế rất gần cách bạn muốn gom nhiều ảnh của cùng patient rồi đưa ra một prediction cấp patient mà không cần label từng ảnh.

1. Lý thuyết / ý tưởng chính

- Authors gom toàn bộ ultrasound images của một patient thành một MIL bag.
- Image features được extract ở nhiều scale (whole frame và patches), rồi attention MIL tổng hợp thành patient representation.
- Clinical variables có thể concat vào aggregated feature trước classification; paper cũng ensemble các model ở scale khác nhau.

2. Cấu trúc / pipeline

```
Patient US frames --> image / patch feature extraction --> AMIL --> patient vector
                                                                    |
Clinical variables ----------------------------------------------+ (optional concat)
                                                                    |
                                                                    v
                                                  malignancy classifier
```

3. Cách train / cơ chế học

- Label ở patient level, không cần independent label cho từng ultrasound frame/patch.
- Các scale có thể train thành model riêng rồi average predictions để giảm compute so với một giant multi-scale model.
- Đây là ví dụ tốt để học cách thiết kế data loader “bag per patient”.

4. Kết quả / kết luận cần nhớ

- Paper báo cáo patient-level AUROC/AUPRC tốt hơn baseline clinical-only trong setting của họ.
- Relevance chính là design pattern, không phải dental domain.

5. Liên hệ trực tiếp với ClinDistill

- Cho bạn một mẫu implementation logic cho multi-image patient/checkup classification.
- Gợi ý rằng clinical variables có thể fuse ở patient-level representation, tương tự Teacher của MeMoSA.
- Có thể dùng để biện minh cho “bag-level label, instance labels không bắt buộc”.

6. Nên học gì từ paper này

- Tham khảo data loader và bag-level evaluation.
- Không split images của cùng patient qua nhiều folds.
- Báo cáo patient-level metrics, không average per-image metrics rồi gọi là patient result.

Peer-reviewed

A new learning paradigm: Learning Using Privileged Information (LUPI)

Vapnik & Vashist | Neural Networks | 2009

Paper: https://doi.org/10.1016/j.neunet.2009.06.042

> **Vì sao cần đọc:** Đây là gốc lý thuyết cho chữ "Privileged" trong tên ClinDistill. Hiểu LUPI giúp bạn dùng thuật ngữ đúng: x* được phép có lúc train nhưng không tồn tại lúc test.

1. Lý thuyết / ý tưởng chính

- Learning Using Privileged Information mở rộng supervised learning bằng cách cho Teacher cung cấp thêm x* trong training.
- Train có (x, x*, y), inference chỉ có x.
- Privileged information không phải "feature phụ luôn luôn có"; nếu inference cần x* thì đó là multimodal inference thông thường, không còn đúng LUPI.

2. Cấu trúc / pipeline

```
TRAIN:     (x, x*, y)
              |
      learning with extra teacher information
              |
              v
          model f(x)

INFERENCE: x --> f(x) --> y_hat
```

3. Cách train / cơ chế học

- Paper gốc phát triển trong bối cảnh SVM/LUPI; deep-learning privileged KD là các extension sau này.
- Với ClinDistill: x = visual bag; x* = clinical context/history; y = diagnosis/lesion class.

4. Kết quả / kết luận cần nhớ

- Giá trị chủ yếu là conceptual foundation, không phải architecture để copy vào PyTorch.
- Nó giúp định nghĩa deployment constraint rất rõ: Student phải chạy được khi x* vắng mặt.

5. Liên hệ trực tiếp với ClinDistill

- Thesis terminology: gọi clinical context là "privileged information" chỉ khi bạn thật sự bỏ nó ở Student inference.
- Nếu có thêm clinical-enhanced mode, cần phân biệt rõ privileged training path và optional multimodal inference path.

6. Nên học gì từ paper này

- Dùng LUPI trong Introduction/Methodology để định nghĩa problem setting.
- Không cần dành quá nhiều trang implementation cho SVM+ nếu thesis dùng deep learning.
- Nối LUPI với generalized distillation ở paper tiếp theo.

Peer-reviewed

Unifying Distillation and Privileged Information (Generalized Distillation)

Lopez-Paz, Bottou, Schölkopf & Vapnik | ICLR | 2016

Paper: https://arxiv.org/abs/1511.03643

Vì sao cần đọc: Paper này là cầu nối lý thuyết trực tiếp giữa LUPI và KD - đúng nền tảng học thuật cho ClinDistill.

1. Lý thuyết / ý tưởng chính

- Generalized Distillation hợp nhất knowledge distillation và privileged information.
- Teacher học từ privileged representation x*; Student học từ normal input x nhưng được hướng dẫn bởi teacher soft targets.
- Framework giải thích vì sao x* có thể giúp Student dù x* không tồn tại lúc test: Teacher biến x* thành một target distribution dễ học hơn hard labels.

2. Cấu trúc / pipeline

```
Privileged x* --> Teacher --> soft targets
                                |
Normal x ----------------------+---> Student
Ground truth y ----------------+---> Student --> inference on x
```

3. Cách train / cơ chế học

- Thường Student loss là kết hợp hard-label loss và imitation/distillation loss từ Teacher.
- Temperature/soft targets truyền relative class similarity thay vì chỉ one-hot target.
- Đây chính là abstraction mà MMPKD hiện đại hóa cho multimodal medical setting.

4. Kết quả / kết luận cần nhớ

- Paper cung cấp theoretical/causal insight và mở rộng tới unsupervised, semi-supervised và multitask scenarios.
- Không phải dental paper, nhưng là citation nền tảng rất đúng với tên ClinDistill.

5. Liên hệ trực tiếp với ClinDistill

- Dùng framework này để viết problem formulation của thesis.
- Cho thấy ClinDistill là một domain-specific extension chứ không phải invent KD từ đầu.
- Novelty nên nằm ở “what privileged knowledge to transfer” và “how to transfer selectively”, không phải ở việc có Teacher-Student.

6. Nên học gì từ paper này

- Trong thesis, cite cùng Hinton KD + LUPI + generalized distillation để tạo nền tảng lý thuyết sạch.
- Viết notation thống nhất x, x*, y ngay từ đầu để architecture sau này dễ hiểu.

Peer-reviewed

Distilling the Knowledge in a Neural Network

Hinton, Vinyals & Dean | NIPS Deep Learning Workshop | 2015

Paper: https://arxiv.org/abs/1503.02531

Vì sao cần đọc: Paper nền tảng của KD. Bạn cần hiểu temperature và soft targets trước khi dùng bất kỳ biến thể selective/privileged KD nào.

1. Lý thuyết / ý tưởng chính

- Knowledge Distillation nén knowledge từ Teacher/ensemble vào Student bằng soft probability distribution.
- Soft targets chứa “dark knowledge”: quan hệ tương đối giữa các classes mà one-hot label không biểu diễn.
- Temperature T > 1 làm distribution mềm hơn để Student nhìn rõ các class similarities.

2. Cấu trúc / pipeline

```
Input --> Teacher --> logits / T --> soft distribution p_T
Input --> Student --> logits / T --> p_S
                        |
        hard CE(y) + soft distillation loss(p_T, p_S)
                        |
                        v
                    Student
```

3. Cách train / cơ chế học

- Vanilla baseline cho ClinDistill có thể dùng CE/BCE + KL divergence giữa temperature-scaled teacher/student outputs.
- Thường nhân KD term với T^2 để cân bằng gradient scale khi dùng temperature.
- Alpha/lambda kiểm soát trade-off giữa hard labels và Teacher signal.

4. Kết quả / kết luận cần nhớ

- Paper nền tảng, không medical-specific.
- Quan trọng vì mọi CPKD/MMPKD/selective KD đều xây trên concept này.

5. Liên hệ trực tiếp với ClinDistill

- Đây là baseline toán học trực tiếp cho loss của ClinDistill trước khi thêm selective weighting.
- Giúp định nghĩa teacher soft targets, temperature và trade-off giữa hard-label supervision với teacher guidance.

6. Nên học gì từ paper này

- Implement vanilla KD unit test trước khi thêm field-aware weighting.
- Log cả hard loss và KD loss để debug.
- Tune T và alpha trên validation; không lấy mặc định từ paper khác mà không kiểm chứng.

3. Ma trận so sánh literature

Paper	Domain	Multi-image	Clinical	Privileged	KD	Inference	Giá trị
CODe	Dental	Có	Có	Không	Không	VLM multimodal	Dataset + benchmark
MeMoSA	Oral lesion	Có	Có	Không	Không	Dataset	Clinical dependency
CPKD	Pancreas	Không	Không	Có	Có	Primary-only	Selective/prior-guided KD
MMPKD	Radiology	Không	Text/tabular	Có	Có	Image-only	Vanilla privileged KD baseline
TriDeNT	Histopath.	Không	Privileged modality	Có	Representation	Primary-only	Feature/SSL transfer
Silva et al.	Dental	Không	Reports	Gián tiếp	Không	Image classifier	Text-derived supervision
Oral cancer fusion	Oral lesion	Không	Tabular clinical	Không	Không	Multimodal	Teacher-style fusion baseline
DentVLM	Dental	Multi-view	VQA/text	Không	Không	Multimodal VLM	Dental SOTA context
Attention MIL	Generic/medical	Có	Không	Không	Không	Bag model	Multi-image baseline
Set Transformer	Generic	Có	Không	Không	Không	Set model	Cross-image interaction
Generalized distill.	Generic	N/A	Privileged x*	Có	Có	x-only	Theory

3.1 Khoảng trống nghiên cứu hợp lý cho ClinDistill

- Không claim “first clinical KD” hoặc “first privileged KD”: prior art đã có CPKD, MMPKD, TriDeNT và generalized distillation.
- Không claim “first dental multimodal AI”: CODe benchmark, Silva et al., DentVLM và oral image + metadata studies đã tồn tại.
- Khoảng trống đáng nhắm: selective transfer từ clinical fields khác nhau vào visual-only multi-image Student ở oro-dental setting.
- CODe kiểm tra knowledge có visual grounding cao (examination/radiographic findings); MeMoSA kiểm tra history/risk factors có low visual grounding hơn.
- Một contribution mạnh là để model học “khi nào Teacher knowledge có thể transfer sang visual Student” thay vì distill tất cả như nhau.

```
Clinical fields
   |
   +-- visual-grounded ---------> high KD weight
   +-- partially grounded ------> learned / moderate weight
   `-- clinical-only -----------> low/no visual distillation
                                  (keep for Teacher reasoning)

                + multi-image visual bag
                v
           ClinDistill Student
```

4. Từ literature tới kế hoạch thực nghiệm

Nguyên tắc: Đừng bắt đầu bằng "final model". Mỗi bước phải có baseline rõ và chỉ thêm một ý mới để biết improvement đến từ đâu.

Experiment	Mục tiêu
E0 - Split/Audit	Patient/checkup/encounter-disjoint split; audit duplicates, follow-up, leakage fields, class balance.
E1 - Single-image baseline	1 ảnh/case hoặc canonical view; 2D encoder + classifier.
E2 - Multi-image baseline	Mean pooling -> max pooling -> Attention MIL.
E3 - Strong aggregator	Set Transformer hoặc attention aggregator có modality/view embedding.
E4 - Clinical Teacher	Visual bag + safe clinical fields -> simple late-fusion Teacher.
E5 - Vanilla privileged KD	Teacher soft logits -> image-only Student; baseline theo generalized distillation/MMPKD.
E6 - Feature KD	Align Teacher/Student representations nếu logit KD chưa đủ.
E7 - Selective ClinDistill	Field/sample-level weights theo visualizability/clinical dependency.
E8 - Cross-dataset validation	Lặp method trên MeMoSA sau CODe; không merge labels.
E9 - Shared weights (optional)	Sau khi E1-E8 ổn mới thử shared visual backbone + dataset-specific adapters/heads.

4.1 Loss tối thiểu nên triển khai trước

Vanilla KD baseline: `L = (1 - alpha) * L_sup(y, p_s) + alpha * T^2 * KL(p_t^T || p_s^T)`

- L_sup: Cross-Entropy cho single-label hoặc BCEWithLogits cho multi-label.
- T: temperature; alpha: trọng số KD.
- Chỉ sau khi baseline ổn mới thêm feature alignment hoặc selective field/sample weights.

4.2 Ablation tối thiểu để paper/thesis có logic

1. Image-only single-image.
2. Multi-image + mean pooling.
3. Multi-image + Attention MIL.
4. Multimodal Teacher (không KD) để đo "clinical context có thực sự thêm signal không?".
5. Vanilla KD Student.
6. Selective/field-aware KD Student.
7. Clinical-field ablation: complaint only; history; examination; risk factors; full safe context.
8. CODe vs MeMoSA independent validation.
9. 3-5 random seeds cho các experiment chính và report mean ± std.

5. Thứ tự đọc paper trước khi bắt đầu code

Thứ tự	Paper và đầu ra cần đạt
Ngày 1	CODe + MeMoSA. Mục tiêu: hiểu data schema, sample unit, labels, leakage fields, licensing/access.
Ngày 2	Hinton KD + LUPI + Generalized Distillation. Mục tiêu: hiểu notation và vanilla KD.
Ngày 3	MMPKD + CPKD. Mục tiêu: biết privileged multimodal KD hiện đại đã làm đến đâu.
Ngày 4	Attention MIL + patient-level thyroid MIL + Set Transformer. Mục tiêu: chốt multi-image aggregator.
Ngày 5	Silva dental report paper + oral cancer multimodal fusion. Mục tiêu: hiểu visual-clinical fusion trong dental/oral domain.
Ngày 6	TriDeNT + KD medical imaging survey. Mục tiêu: feature-level/representation transfer và taxonomy KD.
Ngày 7	DentVLM. Mục tiêu: đặt thesis đúng vị trí so với large dental VLM và chốt phạm vi không cần làm.

5.1 Checklist sau khi đọc xong

- Bạn phải mô tả được một sample của CODe và MeMoSA bằng tensor/field cụ thể.
- Bạn phải biết “bag” multi-image được group ở cấp nào và split ở cấp nào.
- Bạn phải có danh sách clinical fields: giữ / mask / chỉ dùng cho analysis.
- Bạn phải code được Attention MIL baseline trước khi code ClinDistill.
- Bạn phải có một vanilla KD baseline với teacher frozen và visual-only student.
- Bạn phải viết được 1-2 câu rõ ràng: selective ClinDistill khác MMPKD/CPKD ở điểm nào.

6. Cấu trúc Related Work gợi ý cho khóa luận

10. 2.1 Oro-dental multimodal datasets: CODe, MeMoSA và các dental/oral datasets liên quan.
11. 2.2 Multi-image / multiple-instance learning: MIL, attention aggregation, Set Transformer.
12. 2.3 Multimodal clinical learning in dentistry/oral oncology: text reports, metadata, VLMs.
13. 2.4 Knowledge Distillation in medical imaging: logit, feature, relation, cross-modal KD.
14. 2.5 Learning Using Privileged Information and generalized distillation.
15. 2.6 Research gap: selective privileged clinical knowledge transfer for visual-only multi-image oro-dental diagnosis.

Cách viết gap: Không viết “chưa ai dùng KD trong nha khoa” nếu chưa có bằng chứng exhaustive. Viết thận trọng hơn: “Trong literature được rà soát, các hướng hiện có xử lý multi-image aggregation, multimodal dental diagnosis và privileged KD chủ yếu tách rời; chưa thấy một framework đánh giá có hệ thống selective clinical-field transfer sang visual-only multi-image Student trên cả CODe và MeMoSA.”

7. Danh sách link paper và code

Tài liệu	Link
CODe dataset	https://doi.org/10.1038/s41597-026-07342-9
MeMoSA dataset	https://doi.org/10.1038/s41597-026-06998-7
CPKD	https://doi.org/10.1016/j.media.2026.104041
CPKD code	https://github.com/Hanqiaoyu/CPKD
MMPKD	https://arxiv.org/abs/2508.06558
TriDeNT	https://doi.org/10.1016/j.media.2025.103479
Silva et al. dental report + PAN	https://doi.org/10.1016/j.media.2025.103709
Multimodal oral cancer fusion	https://doi.org/10.1038/s41598-026-52410-0
DentVLM	https://doi.org/10.1038/s41467-026-75718-x
KD in medical imaging survey	https://doi.org/10.1016/j.media.2025.103819
Attention-based Deep MIL	https://proceedings.mlr.press/v80/ilse18a.html
Set Transformer	https://proceedings.mlr.press/v97/lee19d.html
Patient-level thyroid AMIL	https://pmc.ncbi.nlm.nih.gov/articles/PMC10785838/
Learning Using Privileged Information	https://doi.org/10.1016/j.neunet.2009.06.042
Unifying Distillation and Privileged Information	https://arxiv.org/abs/1511.03643
Distilling the Knowledge in a Neural Network	https://arxiv.org/abs/1503.02531

7.1 Mức ưu tiên nếu chỉ đọc 6 paper trước khi code

- 1) CODe - hiểu dataset phát triển chính.
- 2) MeMoSA - hiểu clinical dependency và external domain.
- 3) Attention-based Deep MIL - dựng multi-image baseline.
- 4) MMPKD - dựng vanilla privileged KD baseline.
- 5) CPKD - thấy cách biến privileged KD thành method có novelty bằng priors/selective transfer.
- 6) Silva et al. hoặc oral cancer multimodal fusion - nối method với dental/oral clinical context.

8. Ghi chú về nguồn và phạm vi

- Tài liệu này được biên soạn từ các trang publisher/DOI, PubMed/PMLR/arXiv và mô tả public của các paper, cập nhật đến 11/09/2026.
- Các mô tả architecture/loss chỉ được trình bày ở mức mà nguồn công khai hỗ trợ. Với CPKD và một số paper có full text giới hạn, cần đọc full paper/code trước khi tái tạo chính xác từng block.
- “Khoảng trống nghiên cứu” là kết luận từ literature search có mục tiêu, không phải chứng minh tuyệt đối rằng không tồn tại bất kỳ paper nào khác. Trước khi submit journal cần thực hiện một systematic/near-systematic search mới theo thời điểm nộp.
- Tài liệu này ưu tiên mục tiêu khóa luận: CODe + MeMoSA, 2D multi-image, privileged clinical context, visual-only Student. Các hướng 3D/CBCT được để ngoài scope khởi đầu.

Điểm chốt: Nếu bắt đầu implementation ngay: (1) audit/split CODe; (2) single-image baseline; (3) Attention MIL; (4) simple multimodal Teacher; (5) vanilla MMPKD-style KD; (6) mới thiết kế Selective ClinDistill. Làm theo thứ tự này sẽ giúp mỗi improvement có nguyên nhân rõ ràng.